Neural network notes

Marco Marini

January 6, 2016

Contents

1	Generale	1
2	Funzione di costo	2
3	Back-propagation	3
4	Ritorni	3

Abstract

This document contains notes about neural network regarding the Temporal Differential reinforcement alghorithms.

1 Generale

Siano data una rete neurale formata da N strati di neuroni. Ogni strato $i=1\dots N$ è composto da s_i neuroni.

Il primo strato

$$H_{1i} = x_i$$

rappresenta i valori d'ingresso della rete. Per utilità indicheremo i segnali fissi di polarizzazione con

$$H_{i0} = 1$$

Ogni neurone elabora segnali afferenti dal proprio livello e produrrà un segnale uscita verso i livelli sucessivi. Prendiamo in esame una rete NLR (Non Linear regression)

La funzione di trasferimento di ogni neurone nascosto i < N è

$$H_{(i+1)j} = \frac{1}{1 + e^{-Z_{ij}}}$$

$$Z_{ij} = \sum_{k=0}^{s_i} w_{ijk} H_{ik}$$
(1)

la funzione di trasferimento dello strato di uscita N è

$$H_{Nj} = \sum_{k=0}^{s_{N-1}} w_{(N-1)jk} H_{(N-1)k}$$
 (2)

2 Funzione di costo

Sia y_j l'uscita attesa per il neurone j, definiamo l'errore del neurone con

$$\delta_{(N-1)j} = y_j - H_{Nj} \tag{3}$$

La funzione costo della rete è definita come

$$J = \begin{vmatrix} \frac{1-\alpha}{2} \sum_{i=1}^{s_N} \delta_{(N-1)i}^2 + \frac{\alpha}{2} \sum_{i,j,k} w_{ijk}^2, & k \ge 1 \\ \frac{1-\alpha}{2} \sum_{i=1}^{s_N} \delta_{(N-1)i}^2, & k = 0 \end{vmatrix}$$

dove α è il fattore di regolarizzazione della rete.

Calcoliamo ∇J

$$\frac{\partial}{\partial w_{ijk}}J = \begin{vmatrix} (1-\alpha)\sum_{r=1}^{s_N} \delta_{(N-1)r} \frac{\partial}{\partial w_{ijk}} \delta_{(N-1)r} + \alpha w_{ijk}, & k \ge 1 \\ (1-\alpha)\sum_{r=1}^{s_N} \delta_{(N-1)r} \frac{\partial}{\partial w_{ijk}} \delta_{(N-1)r}, & k = 0 \end{vmatrix}$$

Per la (3) abbiamo

$$\frac{\partial}{\partial w_{ijk}} \delta_{(N-1)r} = -\frac{\partial}{\partial w_{ijk}} H_{Nr}$$

quindi

$$\frac{\partial}{\partial w_{ijk}}J = \begin{vmatrix} -(1-\alpha)\sum_{r=1}^{s_N} \delta_{(N-1)r} \frac{\partial}{\partial w_{ijk}} H_{Nr} + \alpha w_{ijk}, & k \ge 1 \\ -(1-\alpha)\sum_{r=1}^{s_N} \delta_{(N-1)r} \frac{\partial}{\partial w_{ijk}} H_{Nr}, & k = 0 \end{vmatrix}$$

Per ora trascuriamo gli effetti di regolarizzazione della rete Per la (2) abbiamo

$$\frac{\partial}{\partial w_{(N-1)jk}} H_{Nj} = H_{(N-1)k}$$
$$\frac{\partial}{\partial w_{(N-1)jk}} H_{Nr} = 0, \ r \neq j$$

quindi

$$\frac{\partial}{\partial w_{(N-1)jk}}J = -\delta_{(N-1)j}H_{(N-1)k}$$

Per la (2) e $i \leq N-2$ abbiamo

$$\frac{\partial J}{\partial w_{ijk}} = -\sum_{r} \delta_{(N-1)r} \frac{\partial}{\partial w_{ijk}} \left[\sum_{s} w_{(N-1)rs} H_{(N-1)s} \right] =$$

$$= -\sum_{r,s} \delta_{(N-1)r} w_{(N-1)rs} \frac{\partial}{\partial w_{ijk}} H_{(N-1)s}$$

Dalla (1) abbiamo

$$\frac{\partial}{\partial w_{ijk}} H_{(i+1)j} = \frac{\partial}{\partial Z_{ij}} H_{(i+1)j} \frac{\partial}{\partial w_{ijk}} Z_{ij} = H_{(i+1)j} (1 - H_{(i+1)j}) Hik$$

Quindi

$$\frac{\partial}{\partial w_{(N-2)jk}}J = -\sum_{r} \delta_{(N-1)r} w_{(N-1)rj} H_{(N-1)j} (1 - H_{(N-1)j}) H_{(N-2)k}$$

3 Back-propagation

Definiamo ora

$$\delta_{(N-2)j} = \sum_{r} \delta_{(N-1)r} w_{(N-1)rj} H_{(N-1)j} (1 - H_{(N-1)j})$$

Avremo allora

$$\frac{\partial}{\partial w_{(N-2)jk}}J = -\delta_{(N-2)j}H_{(N-2)k}$$

Induttivamente ricaviamo per $i \leq N-2$

$$\delta_{ij} = \sum_{k} \delta_{(i+1)k} w_{(i+1)kj} H_{(i+1)j} (1 - H_{(i+1)j})$$

mentre in generale

$$\frac{\partial}{\partial w_{ijk}}J = -\delta_{ij}H_{ik}$$

Definiamo ora il tensore di back-propagation come

$$B_{ijk} = w_{(i+1)kj}H_{(i+1)j}(1 - H_{(i+1)j}), i \le N - 2$$

L'errore sui livelli intermedi è dato da

$$\delta_{ij} = \sum_{k=1}^{s_i} \delta_{(i+1)k} B_{ijk}, \ i = 1 \dots N - 2$$

Reintroducendo la regolarizzazione otteniamo

$$\frac{\partial}{\partial w_{ijk}} J = \begin{vmatrix} -(1-\alpha)\delta_{ij}H_{ik} + \alpha w_{ijk}, & k \ge 1\\ -(1-\alpha)\delta_{ij}H_{ik}, & k = 0 \end{vmatrix}$$

La correzione dei pesi della rete per ridurre l'errore (gradient descent) sarà quindi

$$\Delta w_{ijk} = -\eta \frac{\partial}{\partial w_{ijk}} J = \begin{vmatrix} \eta \left[(1 - \alpha) \delta_{ij} H_{ik} - \alpha w_{ijk} \right], & k \ge 1 \\ \eta (1 - \alpha) \delta_{ij} H_{ik}, & k = 0 \end{vmatrix}$$

con η fattore di apprendimento.

4 Ritorni

Prendiamo un processo dove la strategia migliore genera un episodio di lunghezza infinita e con premio $r_+ > 0$ ogni n passi mentre una scelta diversa al passo n produce la fine dell'episodio con premio $r_- < 0$.

Al passo n il ritorno sarà quindi

$$R_{+} = \frac{r_{+}}{1 - \lambda^{2(n-1)}}$$

se si segue la strategia migliore o nel caso opposto

$$R_-=r_-$$

Poniamo poi che $R_+ \gg -R_-$ avremo quindi che

$$\frac{r_+}{1-\lambda^{2(n-1)}} \gg -r_-$$

$$r_{+} \gg -(1 - \lambda^{2(n-1)})r_{-}$$

Ad esempio posto $\lambda^{2(n-1)}=\frac{1}{2}, r_-=-1$ avremo

$$r_+\gg \frac{1}{2}$$

come ad esempio $r_+=5$